PROPOSAL

"Klasifikasi Penggunaan Helm untuk Mengidentifikasi Pelanggaran Pengendara Bermotor Berbasis Machine Learning"

Disusun untuk memenuhi tugas mata kuliah Pengolahan Citra Digital

Andika Wahyu Dwi Saputra (25/557982/PA/23452)

Dhimas Arya Cahya Nugraha (25/559648/PA/23548)

Jasmine Anendra C.N. (25/557056/PA/23396)

Musvi Aulia Raharjo (25/559633/PA/23546)

Nidya Azza (25/561611/PA/23679)

MAHASISWA PROGRAM STUDI S1 ILMU KOMPUTER

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS GADJAH MADA

2026

DAFTAR ISI

1 Pendahuluan **3**

1.1 Latar Belakang 3

1.2 Perumusan Masalah 5

1.3 Batasan Penelitian 6

1.4 Tujuan 6

2 Landasan Teori **8**

2.1 Kajian Pustaka 8

2.2 Landasan Teori 10

2.2.1 Pengolahan Citra Digital 10

2.2.2 Histogram of Oriented Gradients (HOG) 12

2.2.3 Local Binary Pattern (LBP) 13

2.2.4 Hu Moments 14

2.2.5 Support Vector Machine (SVM) 16

2.2.6 Contrast Limited Adaptive Histogram Equalization (CLAHE) . . 17

3 Metodologi **18**

3.1 Deskripsi Umum 18

3.2 *Dataset* 19

3.3 Prapemrosesan dengan Mengambil *Region of Interest* (ROI) dan Penskalaan Citra 20

3.4 Ekstraksi Fitur 21

3.5 Pelatihan Model 22

3.6 Metrik Evaluasi 23

BAB I
PENDAHULUAN

1.1. Latar Belakang

Sepeda motor merupakan salah satu moda transportasi darat yang banyak digunakan oleh masyarakat Indonesia karena harganya yang relatif terjangkau bagi berbagai kalangan. Berbeda dengan kendaraan roda empat, sepeda motor tidak memiliki rangka pelindung bagi pengendaranya sehingga risiko cedera akibat benturan pada saat kecelakaan menjadi lebih besar. Laporan *Global Status Report on Road Safety 2023* dari World Health Organization (WHO) mencatat bahwa kecelakaan lalu lintas masih menyebabkan sekitar 1,19 juta kematian setiap tahun di seluruh dunia dan lebih dari separuh korban tersebut merupakan pengguna jalan rentan, termasuk pejalan kaki, pesepeda, serta pengendara kendaraan roda dua dan tiga bermotor [1]. Tinjauan sistematis dan meta-analisis yang dilakukan oleh Abdi *et al.* [2] pada negara-negara berpenghasilan rendah dan menengah-bawah menunjukkan bahwa penggunaan helm berkaitan dengan penurunan risiko cedera kepala berat hingga 88% (OR = 0,118; 95% CI: 0,014–0,968; p = 0,049). Meskipun demikian, penerapan aturan wajib helm di berbagai negara berpenghasilan rendah dan menengah masih menghadapi sejumlah kendala, antara lain keterbatasan ketersediaan helm berstandar serta penegakan hukum yang belum optimal [1].

Kondisi keselamatan lalu lintas juga menjadi permasalahan di Indonesia. Korps Lalu Lintas Kepolisian Negara Republik Indonesia (Korlantas Polri) mencatat bahwa hingga September 2024 jumlah kecelakaan lalu lintas telah mencapai lebih dari 111.000 kejadian dengan sekitar 20.000 korban jiwa. Dari jumlah kecelakaan tersebut, sebanyak 74% melibatkan pengemudi kendaraan roda dua, sedangkan 60% dari korban kecelakaan merupakan pengemudi seTingginya keterlibatan pengendara sepeda motor dalam kecelakaan menunjukkan bahwa kelompok pengguna kendaraan tersebut memiliki peranan penting dalam upaya peningkatan keselamatan berlalu lintas. Sementara itu, berdasarkan analisis Tana *et al.* terhadap data Riset Kesehatan Dasar (Riskesdas) 2018, kecelakaan bermotor merupakan penyebab cedera terbesar di Indonesia sebesar 40,6%, sedangkan individu yang tidak menggunakan helm memiliki risiko mengalami cedera kepala 1,17 kali lebih tinggi dibandingkan individu yang menggunakan helm [3].

Pemerintah Indonesia telah mewajibkan penggunaan helm yang memenuhi Standar Nasional Indonesia (SNI) bagi pengendara dan penumpang sepeda motor sebagaimana diatur dalam Pasal 106 ayat (8) Undang-Undang Republik Indonesia Nomor 22 Tahun 2009 tentang Lalu Lintas dan Angkutan Jalan [4]. Namun, pelanggaran berupa tidak menggunakan helm masih ditemukan dalam berbagai kegiatan penertiban lalu lintas. Pengawasan terhadap pelanggaran tersebut masih dapat melibatkan pengamatan secara langsung oleh petugas di lapangan maupun pemantauan rekaman kamera pengawas (*Closed-Circuit Television*/CCTV). Pengawasan secara manual memiliki keterbatasan ketika jumlah citra atau rekaman yang harus diamati semakin besar, terutama berkaitan dengan kebutuhan sumber daya manusia, durasi pengawasan, dan konsistensi proses pengamatan. Kondisi tersebut mendorong pengembangan sistem otomatis yang mampu mengidentifikasi penggunaan helm pada pengendara sepeda motor dari citra secara cepat dan konsisten.

Berbagai penelitian telah dilakukan untuk mengembangkan sistem deteksi maupun klasifikasi penggunaan helm pada pengendara sepeda motor. Pendekatan berbasis *deep learning*, seperti *Convolutional Neural Network* (CNN) dan keluarga metode *You Only Look Once* (YOLO), banyak digunakan karena mampu melakukan pembelajaran fitur secara otomatis dari data citra. Di sisi lain, pendekatan *machine learning* konvensional dengan ekstraksi fitur secara eksplisit (*handcrafted feature*) tetap relevan untuk dikaji, terutama ketika kompleksitas model dan kebutuhan komputasi menjadi pertimbangan.

Dahiya *et al.* [5] mengembangkan sistem untuk mendeteksi pengendara sepeda motor yang tidak menggunakan helm berdasarkan video pengawasan secara *real-time*. Penelitian tersebut mengevaluasi beberapa descriptor, yaitu *Histogram of Oriented Gradients* (HOG), *Scale-Invariant Feature Transform* (SIFT), dan *Local Binary Pattern* (LBP), dengan metode klasifikasi berbasis *Support Vector Machine* (SVM). Hasil penelitian menunjukkan bahwa pendekatan berbasis fitur visual dan SVM dapat digunakan untuk membedakan penggunaan helm pada pengendara sepeda motor.

Sthevanie, Kurniawan, dan Ramadhani [6] juga mengembangkan sistem deteksi helm pada video pengendara sepeda motor menggunakan HOG sebagai metode ekstraksi fitur. Fitur yang diperoleh selanjutnya diklasifikasikan menggunakan SVM dengan *kernel polynomial*. Sistem tersebut menghasilkan nilai *F-measure* sebesar 90,67%. Penelitian tersebut menunjukkan bahwa karakteristik gradien yang direpresentasikan melalui HOG

dapat digunakan sebagai informasi untuk proses klasifikasi helm menggunakan SVM.

Selain HOG dan LBP, informasi bentuk objek dapat direpresentasikan menggunakan *Hu Moments*. Wu dan Zhao [7] mengembangkan sistem identifikasi helm pada lingkungan kerja dengan memanfaatkan beberapa jenis fitur visual. Pada tahap identifikasi helm, penelitian tersebut menggabungkan LBP, *Hu Moment Invariants*, dan histogram warna sebelum dilakukan klasifikasi menggunakan *Hierarchical Support Vector Machine* (H-SVM). Pendekatan tersebut menghasilkan rata-rata akurasi identifikasi helm sebesar 90,3%. Penelitian tersebut menunjukkan bahwa penggabungan fitur yang merepresentasikan karakteristik visual berbeda dapat dimanfaatkan dalam proses identifikasi helm.

Berdasarkan penelitian terdahulu, HOG, LBP, dan *Hu Moments* memiliki karakteristik representasi yang saling melengkapi. HOG dapat digunakan untuk merepresentasikan distribusi orientasi gradien dan karakteristik bentuk objek, sedangkan LBP merepresentasikan pola tekstur lokal pada citra. Sementara itu, *Hu Moments* menyediakan representasi bentuk berdasarkan karakteristik momen citra. Oleh karena itu, penelitian ini mengembangkan sistem klasifikasi penggunaan helm pada pengendara sepeda motor menggunakan penggabungan ketiga fitur tersebut. Pada tahap praproses, *Contrast Limited Adaptive Histogram Equalization* (CLAHE) digunakan untuk meningkatkan kontras citra. Citra selanjutnya direpresentasikan menggunakan HOG, LBP, dan *Hu Moments*, kemudian ketiga vektor fitur digabungkan dan distandarisasi sebelum digunakan sebagai masukan bagi SVM dengan *kernel Radial Basis Function* (RBF). Sistem yang dikembangkan ditujukan untuk melakukan klasifikasi citra ke dalam kelas helm dan tidak menggunakan helm sehingga dapat dikaji sebagai salah satu pendekatan berbasis *machine learning* konvensional untuk mendukung proses identifikasi penggunaan helm secara otomatis.

1.2. Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini berupaya menjawab beberapa permasalahan utama. Pertama, bagaimana merancang sebuah sistem yang mampu mendeteksi keberadaan pengendara sepeda motor pada suatu citra secara akurat. Kedua, bagaimana menerapkan teknik pengolahan citra digital untuk mengidentifikasi apakah pengendara sepeda motor yang terdeteksi tersebut mengenakan helm atau tidak. Selanjutnya, perlu dikaji pula teknik atau metode pengolahan citra apa yang paling efek-

tif digunakan untuk membedakan objek helm dengan objek bukan helm, seperti kepala pengendara yang tidak memakai helm, pada citra yang dianalisis. Terakhir, penelitian ini juga berupaya mengukur sejauh mana tingkat akurasi sistem yang dibangun dalam mengklasifikasikan pengendara yang melanggar (tidak memakai helm) dan yang tidak melanggar (memakai helm).

1.3. Batasan Penelitian

Agar penelitian ini tetap fokus dan terarah, maka ditetapkan batasan-batasan sebagai berikut:

1. Data citra yang digunakan dalam penelitian ini adalah dataset EdgeVision, yang terdiri atas 2.392 citra beresolusi tinggi hasil anotasi bounding box pada tiga kelas objek, yaitu BikeWithRider, NoHelmet, dan Helmet.
2. Penelitian ini berfokus pada pengolahan citra diam (*still image*) dan tidak mencakup pemrosesan video secara langsung (*real-time*).
3. Metode ekstraksi fitur yang digunakan dibatasi pada Histogram of Oriented Gradients (HOG) dan Local Binary Pattern (LBP), dengan Support Vector Machine (SVM) sebagai algoritma klasifikasi, sehingga pendekatan yang digunakan bersifat *machine learning* konvensional (*non-deep learning*).
4. Praproses citra dibatasi pada teknik Contrast Limited Adaptive Histogram Equalization (CLAHE) untuk perbaikan kontras citra.
5. Objek yang dideteksi dan diklasifikasikan dibatasi pada pengendara sepeda motor beserta area kepala untuk menentukan penggunaan helm, dan tidak mencakup jenis pelanggaran lalu lintas lain seperti melawan arus atau tidak menggunakan pelat nomor.
6. Sistem yang dibangun tidak mencakup pengenalan identitas pengendara, seperti pengenalan wajah atau pengenalan pelat nomor kendaraan.

1.4. Tujuan

Penelitian ini diharapkan dapat memberikan manfaat, baik secara teoretis maupun praktis, sebagai berikut.

1. Bagi bidang ilmu pengetahuan, penelitian ini diharapkan dapat memperkaya kaji-

an mengenai efektivitas kombinasi ekstraksi fitur HOG dan LBP dengan algoritma klasifikasi SVM, serta peran praproses CLAHE, dalam kasus klasifikasi penggunaan helm, sehingga dapat menjadi referensi bagi penelitian lanjutan di bidang pengolahan citra digital dan *machine learning* untuk keselamatan lalu lintas.

2. Bagi instansi terkait, seperti kepolisian dan dinas perhubungan, hasil penelitian ini dapat menjadi dasar pengembangan sistem pengawasan pelanggaran penggunaan helm secara otomatis, sehingga dapat mendukung upaya penegakan Pasal 106 ayat (8) Undang-Undang Nomor 22 Tahun 2009 secara lebih efisien dibandingkan pengawasan manual.
3. Bagi masyarakat, penelitian ini diharapkan dapat mendukung peningkatan kesadaran dan kepatuhan pengendara sepeda motor dalam menggunakan helm, sehingga dapat berkontribusi pada penurunan risiko cedera kepala dan angka fatalitas akibat kecelakaan lalu lintas.
4. Bagi peneliti, penelitian ini menjadi sarana untuk memperdalam pemahaman dan keterampilan dalam menerapkan teknik pengolahan citra digital serta algoritma *machine learning* konvensional pada permasalahan nyata di bidang keselamatan transportasi.

BAB II
LANDASAN TEORI

2.1. Kajian Pustaka

Berbagai penelitian telah mengembangkan metode klasifikasi dan deteksi penggunaan helm dengan memanfaatkan teknik pengolahan citra dan pembelajaran mesin. Dahiya et al. [5] mengembangkan sistem deteksi pengendara sepeda motor yang tidak menggunakan helm berdasarkan video pengawasan secara *real-time*. Tahapan awal dilakukan menggunakan *background subtraction* dan segmentasi objek untuk memperoleh area pengendara. Selanjutnya, penelitian tersebut membandingkan tiga jenis representasi fitur, yaitu HOG, *Scale-Invariant Feature Transform* (SIFT), dan LBP, untuk menentukan penggunaan helm dengan klasifikasi biner. Hasil pengujian pada data video pengawasan dunia nyata menunjukkan akurasi deteksi sebesar 93,80

Pendekatan lain dikembangkan oleh Wu dan Zhao [7] untuk identifikasi penggunaan helm pada lingkungan kerja industri. Penelitian tersebut menggunakan beberapa tahapan pengolahan citra. HOG dan SVM digunakan untuk mendeteksi pekerja, sedangkan proses identifikasi helm menggunakan suatu *hybrid descriptor* yang menggabungkan LBP, *Hu Moment Invariants*, dan histogram warna. LBP digunakan untuk merepresentasikan informasi tekstur, *Hu Moment Invariants* merepresentasikan karakteristik geometris, sedangkan histogram warna digunakan untuk memperoleh informasi warna helm. Fitur gabungan tersebut kemudian diklasifikasikan menggunakan *Hierarchical Support Vector Machine* (H-SVM) ke dalam kelas helm merah, helm kuning, helm biru, dan bukan helm. Metode tersebut menghasilkan rata-rata akurasi identifikasi helm sebesar 90,3

Penelitian yang lebih baru dilakukan oleh Sutikno et al. [8] dengan menggabungkan descriptor HAAR, HOG, dan LBP untuk klasifikasi objek bergerak dan pengendara sepeda motor yang menggunakan helm. Ketiga descriptor tersebut digabungkan melalui konkatenasi fitur. HAAR digunakan untuk merepresentasikan perbedaan kontras pada citra pengendara, HOG digunakan untuk menangkap karakteristik bentuk, sedangkan LBP digunakan untuk merepresentasikan tekstur pada bagian kepala. Penelitian tersebut juga membandingkan tiga metode klasifikasi, yaitu *Backpropagation Neural Network* (BNN), SVM, dan *Random Forest* (RF). Pengujian menggunakan 1.956 citra menunjukkan bahwa

kombinasi descriptor tersebut menghasilkan akurasi sebesar 96,75

Selain pada klasifikasi helm, kombinasi *Hu Moments* dan SVM juga telah digunakan pada permasalahan klasifikasi citra lainnya. Poetro et al. [9] menggunakan *Hu Moments* sebagai ekstraksi fitur dan SVM sebagai metode klasifikasi untuk identifikasi citra sayuran. Pada penelitian tersebut, citra terlebih dahulu melalui proses segmentasi menggunakan metode Canny, kemudian karakteristik bentuk objek direpresentasikan menggunakan *Hu Moments*. Vektor fitur yang dihasilkan selanjutnya digunakan sebagai masukan bagi SVM untuk membedakan beberapa kelas objek. Evaluasi dilakukan menggunakan skema *5-fold cross-validation*. Meskipun objek yang diklasifikasikan berbeda dengan penelitian klasifikasi helm, penelitian tersebut menunjukkan bahwa *Hu Moments* dapat digunakan sebagai representasi karakteristik bentuk dan dipadukan dengan SVM sebagai metode klasifikasi.

Berdasarkan penelitian-penelitian terdahulu, HOG, LBP, dan *Hu Moments* memiliki karakteristik representasi yang berbeda. HOG merepresentasikan distribusi orientasi gradien sehingga dapat digunakan untuk menggambarkan karakteristik tepi dan bentuk objek. LBP merepresentasikan pola intensitas pada lingkungan lokal piksel sehingga sesuai untuk menggambarkan informasi tekstur. Sementara itu, *Hu Moments* menghasilkan sekumpulan fitur berbasis momen yang dapat merepresentasikan karakteristik bentuk objek. Perbedaan informasi yang direpresentasikan oleh ketiga metode tersebut memberikan dasar bagi penggunaan pendekatan penggabungan fitur.

Pada penelitian ini, HOG, LBP, dan *Hu Moments* digunakan secara bersama untuk membentuk representasi fitur citra. Berbeda dengan Dahiya et al. [5] yang melakukan evaluasi terhadap HOG, SIFT, dan LBP sebagai representasi fitur untuk deteksi penggunaan helm, penelitian ini menggabungkan HOG dan LBP dengan *Hu Moments*. Sementara itu, berbeda dengan Wu dan Zhao [7] yang menggabungkan LBP, *Hu Moment Invariants*, dan histogram warna untuk identifikasi helm berdasarkan warna, penelitian ini menggunakan HOG sebagai fitur berbasis gradien tanpa memanfaatkan histogram warna. Pendekatan penelitian ini juga memiliki kesamaan konsep dengan Sutikno et al. [8] dalam penggunaan konkatenasi beberapa descriptor, tetapi fitur HAAR digantikan dengan *Hu Moments*. Dengan demikian, penggabungan HOG, LBP, dan *Hu Moments* pada penelitian ini ditujukan untuk memperoleh representasi yang mencakup informasi gradien, tekstur,

dan karakteristik bentuk sebelum dilakukan klasifikasi menggunakan SVM dengan *kernel* RBF.

2.2. Landasan Teori

2.2.1. Pengolahan Citra Digital

Secara umum, pengolahan citra digital berarti memproses gambar dua dimensi dengan komputer, dan tujuan utamanya adalah agar citra mudah diinterpretasi oleh manusia maupun mesin. Melalui proses ini, sebuah citra ditransformasikan menjadi citra lain [10]. Citra kerap mengalami penurunan mutu, misalnya berderau, terlalu kontras, kurang tajam, atau kabur, sehingga perlu dimanipulasi menjadi citra lain yang kualitasnya lebih baik [11]. Pengolahan citra juga dibedakan dari grafika komputer dan visi komputer. Pada pengolahan citra, data masukan maupun keluarannya sama-sama berbentuk citra [12].

Sebuah citra digital dapat didefinisikan sebagai fungsi $f(x, y)$ berukuran M baris dan N kolom, dengan x dan y sebagai koordinat spasial. Amplitudo f pada titik (x, y) menyatakan intensitas atau tingkat keabuan citra di titik tersebut [10]. Citra disebut digital apabila koordinat maupun nilai amplitudonya berhingga dan diskret [12]. Citra digital direpresentasikan sebagai matriks berukuran $N \times M$ yang menyatakan resolusi citra. Setiap elemen matriksnya adalah sebuah piksel (*picture element*), dan nilainya menyatakan intensitas atau derajat keabuan piksel tersebut [13]. Sebuah piksel mewakili bagian terkecil citra berupa kotak, dan nilainya berada pada rentang tertentu yang umumnya 0 sampai 255 [10]. Piksel di pojok kiri atas memiliki koordinat $(0, 0)$ [12].

Komputer digital bekerja dengan angka berpresisi terhingga, sehingga hanya citra yang diskret pada koordinat dan nilainya yang dapat diolah. Citra hasil rekaman yang bersifat kontinu perlu dikonversi terlebih dahulu [12]. Proses digitalisasi ini terdiri dari dua tahap. Tahap pertama adalah penerokan (*sampling*), yaitu digitalisasi secara spasial (x, y) yang menentukan berapa banyak piksel yang dibutuhkan untuk merepresentasikan citra kontinu. Tahap kedua adalah kuantisasi, yaitu pengangkaan nilai intensitas $f(x, y)$ menjadi bilangan bulat [13].

Berdasarkan nilai pikselnya, citra digital umumnya dikelompokkan menjadi tiga jenis. Citra berwarna (RGB) menyajikan warna dari komponen merah, hijau, dan biru. Setiap komponen memakai delapan bit sehingga bernilai 0 sampai 255, dan jumlah warna

yang mungkin disajikan mencapai belasan juta [12]. Citra *grayscale* hanya memiliki satu kanal pada setiap pikselnya, yaitu ketika nilai R, G, dan B sama, dan nilainya menunjukkan tingkat intensitas dari hitam hingga putih. Citra ini dapat diperoleh dari citra RGB dengan persamaan berikut [10]:

$$\text{Nilai keabuan} = 0{,}2989 \cdot R + 0{,}5870 \cdot G + 0{,}1140 \cdot B \tag{1}$$

Konversi ke *grayscale* juga dapat dilakukan dengan mengambil rata-rata nilai R, G, dan B [11]. Citra biner hanya memiliki dua kemungkinan nilai piksel, yaitu hitam (0) dan putih (1), dan sering muncul sebagai hasil pengambangan (*thresholding*). Pada pengambangan, piksel citra *grayscale* $f(x, y)$ yang bernilai sama dengan atau lebih besar dari ambang T diberi nilai 1, sedangkan piksel yang lebih kecil dari T diberi nilai 0 [10]:

$$g(x, y) = \begin{cases} 1 & \text{jika } f(x, y) \geq T \\ 0 & \text{jika } f(x, y) < T \end{cases} \tag{2}$$

Kualitas citra biner sangat bergantung pada nilai T yang dipakai. Metode Otsu dapat menentukan nilai T secara otomatis dari citra masukan [10].

Kualitas citra juga dapat terganggu oleh derau (*noise*). Derau dapat timbul karena gangguan fisis pada alat penangkap citra, misalnya debu pada lensa, atau karena proses pengolahan yang tidak sesuai. Tiga jenis derau yang dikenal adalah derau Gaussian, *speckle*, dan *salt and pepper*. Derau *salt and pepper* tampak sebagai titik hitam dan putih seperti tebaran garam dan merica, dan disebabkan oleh kesalahan bit saat pengiriman data, piksel yang tidak berfungsi, serta kerusakan lokasi memori [11]. Derau jenis ini lazim ditangani dengan tapis median, yaitu filter nonlinear yang mengganti nilai sebuah piksel dengan median dari piksel itu dan piksel-piksel tetangganya. Kekurangannya, citra hasil tapis tampak sedikit kabur dan proses pengurutan data memerlukan waktu [11].

Operasi dalam pengolahan citra dikelompokkan menjadi enam jenis, yaitu peningkatan kualitas citra, restorasi citra, kompresi citra, segmentasi citra, analisis citra, dan rekonstruksi citra [12]. Peningkatan kualitas citra (*image enhancement*) bertujuan meningkatkan kualitas tampilan citra bagi pengamatan manusia, atau mengubah citra ke format yang lebih mudah diolah komputer. Salah satu caranya adalah perenggangan kon-

tras (*contrast stretching*). Kontras suatu citra adalah distribusi piksel terang dan gelap. Pada citra berkontras rendah, histogramnya terkumpul rapat pada sebagian kecil nilai piksel, sedangkan citra berkontras baik memiliki rentang nilai piksel yang lebar [10].

Kompresi citra adalah upaya mentransformasikan data citra tanpa menimbulkan perubahan berarti bagi pengamatan mata manusia. Kompresi *lossy* menghilangkan sebagian informasi, sedangkan kompresi *lossless* tidak membuang informasi apa pun sehingga hasil dekompresinya identik dengan data asli [14].

Segmentasi citra adalah proses mempartisi citra menjadi beberapa daerah atau objek berdasarkan sifat-sifat tertentu, misalnya memisahkan objek dari latar belakangnya agar objek dapat dianalisis. Beberapa tekniknya adalah *thresholding* (global maupun lokal adaptif), *connected component labelling*, dan segmentasi berbasis *clustering* seperti K-means, *fuzzy C-means*, dan SOM. Segmentasi juga lazim menjadi langkah awal sebelum fitur objek diambil dan objek diklasifikasikan [12]. Setelah segmentasi, citra biner sering diproses lebih lanjut dengan operasi morfologi. Operasi ini memakai citra masukan, umumnya biner, dan sebuah kernel yang disebut elemen pembentuk struktur. Dilasi memperbesar batas objek sehingga lubang di dalam objek tampak mengecil, sedangkan erosi mempersempit objek sehingga lubangnya membesar [10].

2.2.2. Histogram of Oriented Gradients (HOG)

Histogram of Oriented Gradients (HOG) adalah deskriptor fitur yang menunjukkan kinerja baik pada berbagai tugas *computer vision* [15]. Dasar kerjanya adalah penampilan dan bentuk objek lokal dalam citra yang sering dapat digambarkan oleh distribusi gradien intensitas atau arah tepi. Deskriptor dibentuk dengan membagi citra menjadi sel, yaitu wilayah kecil yang saling terhubung. Untuk setiap sel disusun histogram arah gradien atau orientasi tepi dari piksel-piksel di dalamnya. Gabungan seluruh histogram tersebut menjadi deskriptor citra [16].

Perhitungan Gradien Tahap awal dapat berupa praproses berupa normalisasi warna dan gamma, tetapi tahap ini dilaporkan berdampak kecil pada kinerja [17]. Cara yang paling umum untuk menghitung gradien adalah menerapkan *mask* turunan diskret satu dimensi yang terpusat pada arah horizontal dan vertikal [18]. Dalam praktiknya, data

intensitas citra difilter dengan dua kernel berikut:

$$[-1,\ 0,\ 1] \quad \text{dan} \quad [-1,\ 0,\ 1]^\top \tag{3}$$

Pembentukan Histogram Orientasi Pada tahap ini dibentuk histogram untuk setiap sel. Setiap piksel dalam sel memberikan suara berbobot ke salah satu saluran histogram orientasi, berdasarkan nilai yang diperoleh dari perhitungan gradien. Bentuk sel dapat persegi panjang atau radial, dan saluran histogram tersebar merata pada rentang 0 sampai 180 untuk gradien *unsigned*, atau 0 sampai 360 untuk gradien *signed*. Gradien *unsigned* dengan 9 saluran histogram memberikan hasil deteksi terbaik [17]. Ukuran sel mempengaruhi panjang vektor fitur; semakin kecil ukuran sel, semakin panjang vektor fitur yang dihasilkan [15].

Normalisasi Blok Histogram dinormalisasi pada tingkat blok. Misalkan $\mathbf{v}$ adalah vektor yang belum dinormalisasi dan berisi seluruh histogram dalam satu blok, $\|\mathbf{v}\|_k$ adalah norma-k dari $\mathbf{v}$ untuk $k = 1$ dan 2, dan ε adalah konstanta kecil. Terdapat empat metode normalisasi [17]:

$$\text{L2-norm:} \quad f = \frac{\mathbf{v}}{\sqrt{\|\mathbf{v}\|_2^2 + \varepsilon^2}} \tag{4}$$

$$\text{L1-norm:} \quad f = \frac{\mathbf{v}}{\|\mathbf{v}\|_1 + \varepsilon} \tag{5}$$

$$\text{L1-sqrt:} \quad f = \sqrt{\frac{\mathbf{v}}{\|\mathbf{v}\|_1 + \varepsilon}} \tag{6}$$

Metode keempat, L2-Hys, dihitung dengan mengambil L2-norm terlebih dahulu, memotong (*clipping*) hasilnya pada nilai batas tertentu, lalu menormalisasi ulang.

2.2.3. Local Binary Pattern (LBP)

Konsep Local Binary Pattern (LBP) pertama kali dikemukakan oleh Timo Ojala dan David Harwood dari Universitas Maryland pada tahun 1992. Prinsip kerjanya adalah membandingkan intensitas piksel di titik pusat dengan delapan piksel yang mengelilinginya

[19]. Dalam pengolahan citra, LBP berperan sebagai *descriptor* untuk menganalisis tekstur.

Kode LBP suatu piksel pusat diperoleh dengan menelusuri piksel-piksel tetangganya, baik searah maupun berlawanan arah jarum jam, asalkan aturan yang dipakai konsisten. Pada jendela berukuran 3×3 terdapat delapan perbandingan biner. Hasilnya disusun menjadi deretan bilangan biner 8-bit, lalu dikonversi ke nilai desimal [20]. Untuk piksel dengan sebanyak P tetangga, nilai LBP dirumuskan sebagai berikut:

$$\mathrm{LBP}(P, R) = \sum_{p=0}^{P-1} s(I_p - I_c) \cdot 2^p \tag{7}$$

$$s(x) = \begin{cases} 1 & \text{jika } x \geq 0 \\ 0 & \text{jika } x < 0 \end{cases} \tag{8}$$

Pada persamaan tersebut, R adalah radius, P adalah jumlah titik *sampling*, I_c adalah intensitas piksel pusat, dan I_p adalah intensitas piksel tetangga ke-p.

Dalam membandingkan nilai keabuan, piksel tetangga diberi nilai 1 jika intensitasnya sama dengan atau lebih besar dari piksel pusat, dan diberi nilai 0 jika lebih kecil. Perbandingan dilakukan berurutan, dimulai dari sudut kiri atas, lalu mengikuti arah jarum jam atau berlawanan arah jarum jam sesuai aturan yang ditetapkan.

2.2.4. Hu Moments

Hu Moments, yang pertama kali diperkenalkan oleh Ming-Kuei Hu pada tahun 1962, adalah sekumpulan deskriptor fitur yang digunakan untuk mengenali bentuk atau siluet suatu objek secara global. Keunggulan utama dari Hu Moment adalah sifatnya yang invarian terhadap pergeseran, perubahan ukuran, dan perputaran citra [21]. Sifat ini menjadikannya sangat relevan untuk tugas ekstraksi fitur bentuk objek yang posisi atau ukuran objek di dalam citra dapat bervariasi.

Tahap awal pembentukan deskriptor ini adalah menghitung momen spasial (*raw moments*) dari citra dua dimensi. Untuk citra digital berukuran $M \times N$ dengan intensitas

piksel $I(x, y)$, momen spasial orde ke-$(p + q)$ didefinisikan

$$m_{pq} = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} x^p y^q I(x, y).$$

Agar fitur yang dihasilkan invarian terhadap translasi (pergeseran koordinat objek dari pusat citra), digunakan momen pusat. Pada momen pusat, titik acuan koordinat digeser ke titik berat (*centroid*) citra $(\bar{x}, \bar{y})$ menggunakan Persamaan 9

$$\mu_{pq} = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (x - \bar{x})^p (y - \bar{y})^q I(x, y) \tag{9}$$

dengan nilai $\bar{x} = \frac{m_{10}}{m_{00}}$ dan $\bar{y} = \frac{m_{01}}{m_{00}}$. Agar fitur invarian terhadap perubahan ukuran atau skala, momen pusat tersebut dinormalisasi menggunakan momen pusat orde nol (μ_{00}):

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{\gamma}}$$

dengan $\gamma = \frac{p+q}{2} + 1$ untuk nilai $p + q \geq 2$. Berdasarkan momen pusat yang telah dinormalisasi tersebut, Hu merumuskan tujuh nilai momen (*Hu Moments*) yang invarian terhadap rotasi. Beberapa momen dasar yang paling sering digunakan di antaranya adalah:

$$\phi_1 = \eta_{20} + \eta_{02}$$

$$\phi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2$$

$$\phi_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2$$

Momen-momen selanjutnya (ϕ_4 hingga ϕ_7) dikonstruksi dari kombinasi orde tinggi untuk menangkap detail bentuk siluet yang lebih kompleks. Akan tetapi, nilai Hu Moments dapat memiliki rentang yang berbeda secara signifikan. Oleh karena itu, transformasi logaritmik dapat diterapkan untuk membawa nilai-nilai Hu Moments ke rentang yang lebih seragam sebelum digunakan pada proses selanjutnya [22].

2.2.5. Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah algoritma *machine learning* yang digunakan untuk menyelesaikan persoalan klasifikasi maupun prediksi. Cara kerjanya adalah mencari *hyperplane* optimal yang memisahkan dua kelas data di dalam ruang fitur. *Hyperplane* ini dirancang agar memiliki margin maksimum, yaitu jarak terjauh antara *hyperplane* dan titik data terdekat dari masing-masing kelas. Titik-titik terdekat tersebut dikenal sebagai *support vector* [23].

Hyperplane dapat dibayangkan sebagai garis atau bidang yang terletak di antara dua kelas data. Posisinya ditentukan sedemikian rupa sehingga jarak ke data terdekat dari kedua kelas (margin) menjadi sebesar mungkin. *Support vector* merupakan data yang paling sulit diklasifikasikan karena letaknya sangat dekat, bahkan hampir tumpang tindih, dengan kelas lain. Karena itu, hanya *support vector* yang berperan dalam menghitung dan menentukan *hyperplane* optimal [24].

Untuk klasifikasi biner, fungsi keputusan SVM dinyatakan sebagai berikut:

$$f(x) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b) \tag{10}$$

Dalam persamaan ini, $f(x)$ adalah fungsi keputusan yang menetapkan label kelas bagi data $\mathbf{x}$, $\mathbf{w}$ adalah vektor bobot, $\mathbf{x}$ adalah vektor fitur dari data tersebut, dan b adalah bias. SVM bertujuan menemukan nilai $\mathbf{w}$ dan b yang memaksimalkan margin [25], dengan menyelesaikan masalah optimasi berikut:

$$\min \frac{1}{2}\|\mathbf{w}\|^2 \tag{11}$$

dengan kendala:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 \tag{12}$$

Di sini, y_i adalah label kelas dari data $\mathbf{x}_i$. Apabila data tidak dapat dipisahkan secara linier, SVM dapat memanfaatkan fungsi kernel, seperti kernel linear, polinomial, atau *radial basis function*. Kernel memetakan data ke ruang berdimensi lebih tinggi sehingga data dapat dipisahkan secara linier [24]. SVM tergolong metode yang efektif dan banyak

dipakai untuk klasifikasi, terutama pada data dengan dimensi dan jumlah fitur yang besar.

2.2.6. Contrast Limited Adaptive Histogram Equalization (CLAHE)

Konsep Dasar Contrast Limited Adaptive Histogram Equalization (CLAHE) adalah teknik pengolahan citra yang meningkatkan kontras dengan tetap mempertahankan detail halus pada area berkontras rendah [26]. Teknik ini membagi citra menjadi blok-blok kecil, lalu melakukan pemerataan histogram pada tiap blok dengan batas kontras tertentu, sehingga detail citra menjadi lebih jelas dan kualitas visualnya membaik [27]. Karena bekerja secara lokal, CLAHE dapat mengatasi keterbatasan metode global yang menerapkan satu transformasi yang sama pada seluruh citra [28].

Mekanisme Kerja CLAHE membentuk wilayah kontekstual yang tidak saling tumpang tindih, yang disebut sub-citra, *tile*, atau blok. Pemerataan histogram dilakukan pada masing-masing wilayah tersebut. Histogram asli dipotong pada nilai batas tertentu, lalu piksel kelebihan hasil pemotongan didistribusikan kembali ke seluruh tingkat keabuan [**?**]. Pembatasan ini mencegah kontras naik secara berlebihan.

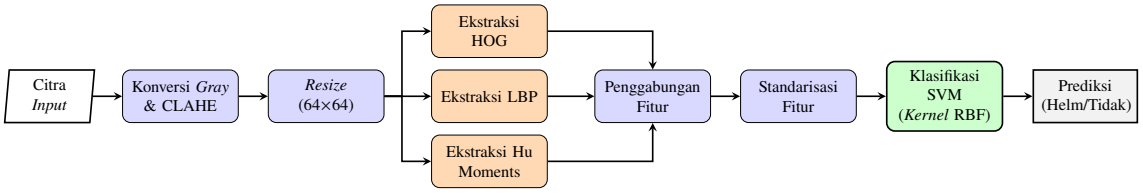
Parameter CLAHE Hasil CLAHE ditentukan oleh dua parameter utama.

- *Clip limit*, yaitu ambang yang membatasi seberapa jauh pemerataan histogram diterapkan pada tiap blok. Nilai yang rendah menghasilkan penyesuaian kontras yang lebih lembut, sedangkan nilai yang tinggi menghasilkan pemerataan yang lebih tajam. Peningkatan kontras yang berlebihan dapat menurunkan kinerja model pembelajaran [26].
- *tileGridSize*, yaitu ukuran grid yang menentukan jumlah blok tempat citra dibagi. Semakin besar nilainya, semakin kecil area yang diproses per blok, sehingga penyesuaian kontras semakin lokal.

Penerapan pada Citra Berwarna Pada citra berwarna, CLAHE umumnya tidak diterapkan langsung pada ketiga kanal RGB. Citra RGB dikonversi terlebih dahulu ke ruang warna Lab dan kanalnya dipisahkan menjadi L, a, dan b. CLAHE hanya diterapkan pada kanal *lightness* (L), lalu kanal digabungkan kembali dan dikonversi ke format RGB [26]. Dengan cara ini, kontras meningkat tanpa mengubah informasi warna secara langsung.

BAB III
METODOLOGI

3.1. Deskripsi Umum



Gambar 1: Diagram alir tahapan prapemrosesan citra, ekstraksi fitur gabungan, hingga klasifikasi menggunakan Support Vector Machine (SVM).

Secara umum, penelitian ini bertujuan untuk membangun sebuah sistem klasifikasi berbasis pengolahan citra digital dan machine learning konvensional yang mampu mengidentifikasi penggunaan helm pada pengendara sepeda motor dari sebuah citra diam (*still image*), sebagai dasar untuk mengidentifikasi pelanggaran terhadap ketentuan wajib helm. Sistem menerima masukan berupa citra pengendara sepeda motor yang bersumber dari dataset EdgeVision, dan menghasilkan keluaran berupa label klasifikasi, yaitu Helmet (memakai helm, tidak melanggar) atau NoHelmet (tidak memakai helm, melanggar).

Sistem dirancang dengan pendekatan *non-deep learning* sehingga seluruh proses pengolahan citra dilakukan melalui rangkaian teknik klasik yang telah dijelaskan pada tinjauan pustaka. Citra masukan mula-mula mengalami perbaikan kualitas melalui teknik Contrast Limited Adaptive Histogram Equalization (CLAHE), yang bertujuan memperbaiki kontras citra agar variasi kondisi pencahayaan pada citra lalu lintas nyata, seperti bayangan, silau, maupun kondisi minim cahaya, tidak menurunkan kualitas fitur yang akan diekstraksi pada tahap berikutnya [26].

Selanjutnya, area kepala pengendara ditentukan sebagai fokus analisis (*region of interest*) dengan memanfaatkan anotasi bounding box yang telah tersedia pada dataset EdgeVision, sehingga proses klasifikasi dapat lebih terarah pada bagian citra yang relevan dengan objek helm.

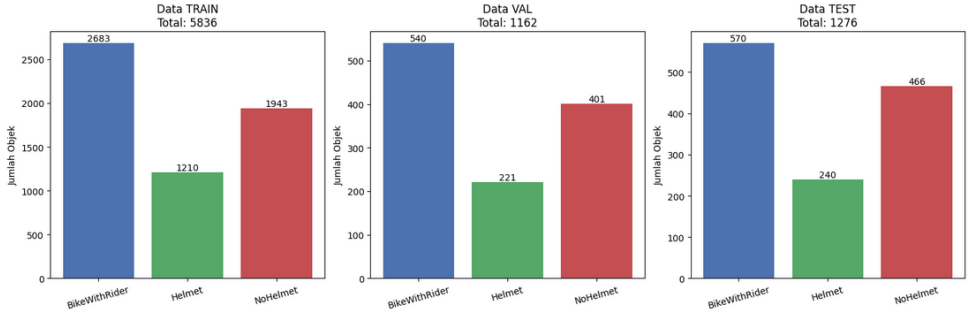
Dari area tersebut, karakteristik bentuk dan tekstur objek kemudian diekstraksi menggunakan kombinasi metode HOG, LBP, dan Hu Moments. HOG dimanfaatkan untuk menangkap informasi bentuk lokal dan orientasi tepi objek [17], LBP difokuskan

untuk mengenali karakteristik tekstur permukaan [19], sementara Hu Moments digunakan untuk mengekstrak informasi distribusi massa dan siluet objek secara global yang invarian terhadap perubahan posisi, ukuran, maupun rotasi [21]. Ketiga fitur ini saling melengkapi untuk menghasilkan representasi citra yang komprehensif dalam membedakan objek helm dan bukan helm. Fitur gabungan yang telah diekstraksi tersebut selanjutnya diklasifikasikan menggunakan algoritma Support Vector Machine (SVM), yang bertugas menentukan hyperplane pemisah optimal antara kedua kelas keputusan sehingga sistem dapat mengklasifikasikan setiap citra pengendara ke dalam kategori melanggar atau tidak melanggar [23, 25].

3.2. *Dataset*

Penelitian ini menggunakan *dataset* EdgeVision, sebuah *dataset* citra yang dikumpulkan dari skenario lalu lintas sepeda motor nyata untuk keperluan deteksi helm. Dataset ini terdiri atas 2.392 citra dengan resolusi yang beragam dan dianotasi oleh lima annotator menggunakan tool Make Sense, menghasilkan 8.275 anotasi bounding box yang mencakup tiga kelas, yaitu BikeWithRider, NoHelmet, dan Helmet.

Pembagian dataset pada sistem ini dilakukan berdasarkan gambar secara utuh , bukan berdasarkan jumlah objek individu. Pendekatan ini sangat krusial untuk mencegah terjadinya kebocoran data (*data leakage*). Jika pembagian dilakukan berbasis objek, terdapat kemungkinan objek-objek dari satu gambar yang sama terpisah ke dalam set latih dan set uji. Hal ini dapat memicu model untuk sekadar menghafal pola latar belakang atau kondisi pencahayaan gambar tersebut, bukan mempelajari fitur objek yang sebenarnya. Dataset kemudian dibagi secara acak dan konsisten dengan proporsi 70% data latih, 15% data validasi, dan 15% data uji. Pemisahan yang ketat ini memastikan bahwa evaluasi kinerja model dilakukan pada citra yang benar-benar baru sehingga hasil akurasi yang didapatkan bersifat objektif dan merepresentasikan kemampuan model di kondisi nyata. Untuk distribusi kelas dari pembagian ini terdapat pada Gambar 2.



Gambar 2: Distribusi Kelas dari Setiap Pembagian Data.

3.3. Prapemrosesan dengan Mengambil *Region of Interest* (ROI) dan Penskalaan Citra

Proses praproses dan ekstraksi ROI dilakukan secara sistematis pada setiap citra berdasarkan koordinat *bounding box*. Citra asli pertama-tama dikonversi ke dalam format *grayscale*, lalu ditingkatkan kualitas kontras lokalnya menggunakan metode CLAHE [26]. Langkah awal ini bertujuan untuk memperjelas detail tekstur dan batas tepi objek, sekaligus meredam variasi efek iluminasi atau pencahayaan yang tidak merata dari lingkungan asli. Setelah citra diperbaiki, area objek dipotong sesuai dengan batasan koordinat masing-masing kelas.

Sebelum operasi pemotongan citra dieksekusi, wilayah pembatas spasial (*bounding box*) awal yang didefinisikan oleh titik asal (x, y) beserta dimensi lebar w dan tinggi h, diperluas melalui penambahan margin toleransi proporsional sebesar β (dengan $\beta > 0$). Secara matematis, proyeksi dimensi wilayah baru direpresentasikan sebagai

$$w' = w(1 + \beta), \qquad h' = h(1 + \beta) \tag{13}$$

Untuk mempertahankan pusat geometris objek, titik asal koordinat digeser secara simetris mendistribusikan margin tersebut ke ruang spasial citra menjadi

$$x' = x - \frac{\beta w}{2}, \qquad y' = y - \frac{\beta h}{2} \tag{14}$$

Penambahan konteks spasial ini memitigasi hilangnya informasi pada batas citra (*boundary clipping*). Bagi deskriptor HOG yang beroperasi berdasarkan fungsi gradien $\nabla I(x, y) = [G_x, G_y]^\top$, pemotongan tanpa margin (*tight crop*) akan mengeliminasi transisi intensitas

pada batas luar siluet (seperti kontur atas helm), sehingga magnitudo dan vektor orientasi gradien tepi pada area tersebut tidak dapat terkomputasi secara utuh.

ROI yang dihasilkan memiliki dimensi $w' \times h'$ dengan rasio aspek $r = \frac{w'}{h'}$ yang bervariasi. Oleh karena itu, matriks tersebut ditransformasikan ke dalam resolusi spasial target yang seragam sebesar $W \times H$ (yakni 64×64 piksel). Transformasi ini menerapkan penskalaan proporsional dengan penambahan bantalan bernilai nol (*resize with zero-padding*). Faktor skala tunggal dihitung melalui persamaan:

$$s = \min\left(\frac{W}{w'}, \frac{H}{h'}\right)$$

Citra awal kemudian diproyeksikan ke dimensi baru $w^* = s \cdot w'$ dan $h^* = s \cdot h'$. Proses pengubahan ukuran citra ini dilakukan menggunakan metode interpolasi area (*area interpolation*), yang bekerja dengan merata-ratakan nilai piksel pada area sumber sehingga efektif untuk meminimalkan artefak visual saat resolusi citra diturunkan. Setelah matriks citra diubah ukurannya, sisa ruang sebesar $\Delta w = W - w^*$ dan $\Delta h = H - h^*$ diisi dengan matriks bernilai nol (latar belakang hitam) yang didistribusikan secara merata pada kedua sisi pembatas.

Penerapan skala yang sama pada kedua sumbu ($s_x = s_y = s$) ini secara fundamental mencegah terjadinya transformasi regangan asimetris yang memicu distorsi geometris. Pelestarian proporsi spasial citra asli merupakan prasyarat mutlak, karena paksaan dimensi citra menjadi persegi panjang akan memodifikasi arah dan orientasi gradien tepi pada perhitungan HOG sehingga menyimpang secara non-linier dari kondisi aslinya. Lebih lanjut, distorsi bentuk juga akan merusak basis perhitungan momen spasial sentral μ_{pq} pada perumusan *Hu Moments* sehingga deskriptor kehilangan sifat invariansinya terhadap bentuk objek. Rangkaian pemodelan praproses ini diaplikasikan secara deterministik pada seluruh himpunan data latih, validasi, dan uji untuk menjamin konsistensi ruang fitur sebelum dievaluasi oleh algoritma Support Vector Machine (SVM).

3.4. Ekstraksi Fitur

Proses ekstraksi fitur pada setiap *Region of Interest* (ROI) dilakukan secara berurutan menggunakan tiga metode yang dikonfigurasi dengan parameter spesifik. Pada algoritma

HOG, digunakan 9 saluran orientasi dengan ukuran sel 8×8 piksel dan ukuran blok 2×2 sel. HOG merepresentasikan karakteristik bentuk objek berdasarkan distribusi orientasi gradien pada wilayah lokal citra [17]. Konfigurasi ini digunakan untuk menangkap arah garis tepi siluet objek secara detail tanpa memperbesar dimensi vektor secara eksesif, sementara normalisasi blok *L2-Hysteresis* diterapkan untuk meredam variasi iluminasi ekstrem. Pada algoritma LBP, digunakan parameter radius 1 piksel dengan 8 titik sampel (*neighbors*) menggunakan metode pola seragam (*uniform pattern*). LBP digunakan untuk merepresentasikan karakteristik tekstur lokal berdasarkan pola intensitas piksel pada lingkungan sekitar [19]. Pengaturan parameter tersebut diterapkan untuk memperoleh representasi tekstur berskala lokal pada ROI. Terakhir, pada *Hu Moments*, hasil perhitungan momen spasial sentral digunakan sebagai representasi karakteristik bentuk objek yang memiliki sifat invarian terhadap translasi, perubahan skala, dan rotasi [21]. Selanjutnya, nilai tersebut dikenakan transformasi logaritmik dengan formulasi $-1 \cdot \text{sign}(h) \cdot \log_{10}(|h|)$. Setelah diekstraksi, ketiga himpunan nilai tersebut digabungkan secara horizontal (*feature fusion*) untuk membentuk satu vektor representasi komprehensif per citra.

Karena vektor gabungan ini tersusun dari metrik dengan rentang nilai yang sangat timpang, yakni magnitudo gradien (HOG), densitas histogram (LBP), dan nilai logaritmik (*Hu Moments*), proses standarisasi data (*standard scaling*) diimplementasikan. Standarisasi dilakukan dengan menghitung nilai rata-rata dan standar deviasi murni dari himpunan data latih, kemudian mengubah distribusinya menjadi skor-Z (rata-rata nol dan variansi satu). Parameter transformasi dari data latih tersebut selanjutnya digunakan untuk menormalisasi himpunan data validasi dan data uji. Pendekatan ini secara fundamental mencegah dominasi pembobotan oleh fitur yang kebetulan memiliki rentang angka besar, sekaligus menjamin tidak adanya kebocoran informasi spasial (*data leakage*) dari set evaluasi ke dalam fase pelatihan model.

3.5. Pelatihan Model

Untuk mengukur tingkat kontribusi independen maupun sinergis dari masing-masing deskriptor, sebuah studi ablasi (*ablation study*) dilakukan secara komprehensif. Seluruh kemungkinan kombinasi dari ketiga fitur utama, yakni HOG, LBP, dan *Hu Moments*, dievaluasi secara bergantian sehingga menghasilkan tujuh skenario pemodelan fitur yang

berbeda. Pada setiap skenario, himpunan fitur yang dievaluasi digabungkan menjadi satu ruang vektor tunggal. Sesuai dengan protokol prapemrosesan data, prosedur standarisasi; parameter transformasi murni dihitung dari data latih, kemudian digunakan untuk menormalisasi data validasi dan data uji. Langkah isolasi ini merupakan metode ini dilakukan untuk memastikan tidak ada kebocoran informasi (*data leakage*) yang dapat memicu bias evaluasi.

Setiap kombinasi ruang vektor fitur tersebut selanjutnya dilatih menggunakan algoritma *Support Vector Machine* (SVM) dengan fungsi kernel *Radial Basis Function* (RBF). Kinerja dari masing-masing model kemudian dievaluasi menggunakan himpunan data validasi dan himpunan data uji. Pemilihan kombinasi fitur paling optimal secara hierarkis didasarkan pada tingkat akurasi tertinggi yang diraih pada fase validasi. Sementara itu, evaluasi terhadap data uji dijadikan sebagai tolok ukur untuk membuktikan kemampuan generalisasi model terhadap data citra yang benar-benar baru dan belum pernah dipelajari sebelumnya

3.6. Metrik Evaluasi

Untuk mengevaluasi keandalan algoritma secara lebih mendalam, digunakan instrumen *Confusion Matrix* yang merepresentasikan perbandingan antara kelas hasil prediksi model dengan kelas aktual. Berdasarkan matriks tersebut, diekstrak tiga metrik evaluasi utama: *Precision*, *Recall*, dan *F1-Score*. Perumusan metrik-metrik ini didasarkan pada empat variabel fundamental dari *Confusion Matrix*, yakni *True Positive* (TP) untuk data positif yang diprediksi benar, *True Negative* (TN) untuk data negatif yang diprediksi benar, *False Positive* (FP) untuk data negatif yang keliru diprediksi sebagai positif, dan *False Negative* (FN) untuk data positif yang keliru diprediksi sebagai negatif.

Precision mengukur tingkat ketepatan atau kepresisian model dalam menebak kelas target. Metrik ini menunjukkan rasio dari prediksi positif yang benar-benar akurat dibandingkan dengan keseluruhan tebakan kelas positif yang dihasilkan oleh model. *Precision* sangat penting untuk mengukur seberapa banyak kesalahan model dalam memberikan alarm palsu (*false alarm*). Rumus matematisnya dinyatakan sebagai:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{15}$$

Recall mengukur tingkat sensitivitas atau keberhasilan model dalam mengenali dan menemukan kembali seluruh porsi data yang secara aktual bernilai positif. Metrik ini menunjukkan kemampuan model dalam mencegah terlewatnya objek yang seharusnya terdeteksi. Perhitungan *Recall* diformulasikan sebagai:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{16}$$

Terdapat kondisi *trade-off* (tarik-ulur) antara *Precision* dan *Recall*; peningkatan pada satu metrik sering kali menyebabkan penurunan pada metrik lainnya. Untuk mengatasi hal tersebut, digunakan *F1-Score* yang merupakan rata-rata harmonik (*harmonic mean*) dari *Precision* dan *Recall*. Nilai *F1-Score* memberikan representasi evaluasi tunggal yang sangat seimbang mengenai performa keseluruhan model. Rumusnya didefinisikan sebagai

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{17}$$

Melalui penjabaran metrik ini, evaluasi terhadap kinerja *Support Vector Machine* (SVM) tidak hanya dinilai dari berapa banyak data yang ditebak secara benar secara keseluruhan, melainkan juga seberapa presisi prediksi tersebut dan seberapa sensitif model dalam mengenali kelas pengendara berhelm dan tidak berhelm secara spesifik.

PUSTAKA

[1] World Health Organization, *Global Status Report on Road Safety 2023*. Geneva, Switzerland: World Health Organization, 2023. [Online]. Available: https://www.who.int/publications/i/item/9789240086517

[2] N. Abdi, T. Robertson, P. Petrucka, and A. M. Crizzle, "Do motorcycle helmets reduce road traffic injuries, hospitalizations and mortalities in low and lower-middle income countries in africa? a systematic review and meta-analysis," *BMC Public Health*, vol. 22, no. 1, p. 824, 2022.

[3] L. Tana, D. Delima, N. Kusumawardani, and L. Indrawati, "Helmet use behavior and its relation to head injury of road traffic accident in indonesia (basic health research, 2018)," *Health Science Journal of Indonesia*, vol. 12, no. 1, pp. 56–65, 2021.

[4] Republik Indonesia, "Undang-undang republik indonesia nomor 22 tahun 2009 tentang lalu lintas dan angkutan jalan," 2009, lembaran Negara Republik Indonesia Tahun 2009 Nomor 96.

[5] K. Dahiya, D. Singh, and C. K. Mohan, "Automatic detection of bike-riders without helmet using surveillance videos in real-time," in *2016 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2016, pp. 3046–3051.

[6] F. Sthevanie, A. Kurniawan, and K. N. Ramadhani, "Deteksi helm pada video pengendara sepeda motor menggunakan ekstraksi ciri histogram of oriented gradients," *Indonesian Journal on Computing*, vol. 5, no. 1, pp. 63–72, 2020.

[7] H. Wu and J. Zhao, "An intelligent vision-based approach for helmet identification for work safety," *Computers in Industry*, vol. 100, pp. 267–277, 2018.

[8] Sutikno, A. Sugiharto, R. Kusumaningrum, and H. A. Wibawa, "Combination of haar, hog, and lbp descriptors for enhanced classification of moving objects and motorcyclists wearing helmets," *Engineering, Technology & Applied Science Research*, vol. 15, no. 3, pp. 23 283–23 289, 2025.

[9] B. S. W. Poetro, E. Maria, H. Zein, E. Najwaini, and D. H. Zulfikar, "Advancements in agricultural automation: Svm classifier with hu moments for vegetable identification," *Indonesian Journal of Data and Science*, vol. 5, no. 1, pp. 15–22, 2024.

[10] R. F. Gusa, "Pengolahan citra digital untuk menghitung luas daerah bekas penambangan timah," *Jurnal Nasional Teknik Elektro*, vol. 2, no. 2, pp. 27–34, 2013.

[11] Yudianingsih and L. Listyalina, "Penentuan kombinasi kernel terbaik menggunakan median filter," *Teknoin*, vol. 22, no. 3, pp. 225–234, 2016.

[12] N. Nafi'iyah, "Algoritma kohonen dalam mengubah citra graylevel menjadi citra biner," *Jurnal Ilmiah Teknologi Informasi Asia*, vol. 9, no. 2, pp. 49–55, 2015.

[13] R. Munir, "Pengantar pengolahan citra," Materi Kuliah IF4073 Interpretasi dan Pengolahan Citra, Bandung, 2019.

[14] W. E. Pangesti, G. Widagdo, D. Riana, and S. Hadianti, "Implementasi kompresi citra digital dengan membandingkan metode lossy dan lossless compression menggunakan matlab," *Jurnal Khatulistiwa Informatika*, vol. 8, no. 1, 2020.

[15] K. Venkateswarlu, N. Sudha, and P. Pavankumar, "Implementing hog features to recognize multilingual characters in machine learning," *Science, Technology and Development*, vol. 9, no. 7, pp. 106–115, 2020.

[16] A. Satpathy, X. Jiang, and H.-L. Eng, "Human detection by quadratic classification on subspace of extended histogram of gradients," *IEEE Transactions on Image Processing*, vol. 23, no. 1, pp. 287–297, 2014.

[17] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*, vol. 1. IEEE, 2005, pp. 886–893.

[18] A. J. Newell and L. D. Griffin, "Multiscale histogram of oriented gradient descriptors for robust character recognition," in *2011 International Conference on Document Analysis and Recognition*. IEEE, 2011, pp. 1085–1089.

[19] R. Purwati and G. Ariyanto, "Pengenalan wajah manusia berbasis algoritma local binary pattern," *Emitor: Jurnal Teknik Elektro*, vol. 17, no. 2, pp. 70–79, 2017.

[20] M. Ismurahayu and A. Nasihin, "Perancangan deteksi pengenalan wajah menggunakan metode local bianary pattern (lbp)," *Jurnal Teknologi Informasi dan Komunikasi*, vol. 9, no. 1, pp. 48–54, 2020.

[21] M.-K. Hu, "Visual pattern recognition by moment invariants," *IRE Transactions on Information Theory*, vol. 8, no. 2, pp. 179–187, 1962.

[22] "Methodology based on the hu moment invariants for object comparison on radar satellite imagery," *Journal of Physics: Conference Series*, vol. 2668, p. 012012, 2023.

[23] P. A. Octaviani, Y. Wilandari, and D. Ispriyanti, "Penerapan metode klasifikasi support vector machine (svm) pada data akreditasi sekolah dasar (sd) di kabupaten magelang," *Jurnal Gaussian*, vol. 3, no. 4, pp. 811–820, 2014.

[24] P. N. Andono and E. H. Rachmawanto, "Evaluasi ekstraksi fitur glcm dan lbp menggunakan multikernel svm untuk klasifikasi batik," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 5, no. 1, pp. 1–9, 2021.

[25] M. Latifudin, R. Kumalasari N., and L. Sinta W., "Klasifikasi kualitas kayu glugu menggunakan metode (support vektor machine) svm," in *Prosiding SEMNAS INOTEK (Seminar Nasional Inovasi Teknologi)*, vol. 6, no. 2, 2022.

[26] A. Wanto, Y. Yuhandri, and O. Okfalisa, "Optimization accuracy of cnn model by utilizing clahe parameters in image classification problems," in *2023 International Conference on Networking, Electrical Engineering, Computer Science, and Technology (IConNECT)*. IEEE, 2023.

[27] R. K. Sidhu, J. Sachdeva, and D. Katoch, "Segmentation of retinal blood vessels by a novel hybrid technique–principal component analysis (pca) and contrast limited adaptive histogram equalization (clahe)," *Microvascular Research*, vol. 148, p. 104477, 2023.

[28] F. M. J. M. Shamrat, S. Azam, A. Karim, K. Ahmed, F. M. Bui, and F. De Boer, "High-precision multiclass classification of lung disease through customized mobilenetv2 from chest x-ray images," *Computers in Biology and Medicine*, vol. 155, p. 106646, 2023.